

Aulas 1 e 2: Questões de treino (lista 2)

Deep Learning (DEPAI) · IASEG/PMERJ · Aulas 1 (05/10) e 2 (06/10)

Fáceis

T01.

Qual lista contém **apenas** hiperparâmetros de uma rede neural?

- a) Os pesos da camada oculta, o bias da camada de saída e a taxa de aprendizado.
- b) O número de camadas, o número de neurônios por camada, a taxa de aprendizado e o tamanho do lote.
- c) Os pesos e os bias de todas as camadas.
- d) O número de épocas, a função de ativação e os pesos da camada de saída.

T02.

Um grupo dividiu seus dados em treino, validação e teste e quer comparar três redes: com 1, 2 e 3 camadas ocultas. Qual procedimento está correto?

- a) Treinar as três no treino, escolher a de maior acurácia no teste e relatar a acurácia de validação.
- b) Escolher a rede de maior acurácia no treino, porque o conjunto de treino é o maior dos três.
- c) Ajustar os pesos no treino, escolher a configuração pela validação e usar o teste uma vez, no fim, para estimar o desempenho em dados novos.
- d) Avaliar as três no teste ao fim de cada época e parar o treino quando o acerto no teste deixar de subir.

T03.

Na programação clássica, alguém escreve as regras, e o computador as aplica aos dados para produzir respostas. Qual alternativa descreve o machine learning, segundo a aula?

- a) O sistema recebe dados e as respostas correspondentes e produz as regras: ele é treinado, e não programado.
- b) O sistema recebe regras e dados e produz respostas, como na programação clássica, só que mais rápido.
- c) O sistema recebe só os dados, sem respostas, e chega sozinho às mesmas regras que um especialista escreveria.
- d) É a IA simbólica: programadores escrevem as regras à mão, e o computador as aplica em grande escala.

T04.

Para separar dígitos escritos à mão, um grupo de ML treinou uma floresta aleatória com colunas calculadas por eles, como o número de laços fechados de cada dígito. Outro grupo deu os pixels da imagem a uma rede profunda. Qual é a diferença central entre as duas abordagens, segundo a aula?

- a) A rede profunda dispensa os rótulos, porque cria as próprias colunas.
- b) Na rede, as colunas são escritas por um especialista, e o treino só decide como combiná-las.
- c) Não há diferença de fundo: as duas recebem as mesmas colunas e só mudam de nome.
- d) No ML, alguém escolhe ou constrói as representações; no deep learning, as representações também são aprendidas a partir dos exemplos, camada por camada.

T05.

Um neurônio tem pesos $w_1 = 2$ e $w_2 = -1$ e bias $b = 1$. Ele recebe $x_1 = 1$ e $x_2 = 4$. Qual é a saída do neurônio com ReLU e com sigmoide?

- a) ReLU: -1 ; sigmoide: 0
- b) ReLU: 1 ; sigmoide: $0,73$
- c) ReLU: 0 ; sigmoide: aproximadamente $0,27$
- d) ReLU: 0 ; sigmoide: $-0,27$

T06.

Uma chamada é de fato trote. A rede A dá $0,9$ de chance para “trote”; a rede B dá $0,1$. Com a entropia cruzada (perda = $-\ln p$, em que p é a chance que a rede deu à resposta certa), qual é a perda de cada rede nesse exemplo?

- a) A: $0,9$; B: $0,1$. A perda é a própria chance dada à resposta certa.
- b) A: $0,11$; B: $2,30$. A rede B é muito mais punida, porque deu pouca chance à resposta certa.
- c) A: $0,01$; B: $0,81$.
- d) A: $2,30$; B: $0,11$.

T07.

Um conjunto de treino tem 2.000 exemplos. O treino usa lotes de 50 exemplos e roda 10 épocas. Quantas vezes os pesos são atualizados, e o que acontece em cada atualização?

- a) 10 ; em cada época, os pesos andam na direção do gradiente, a direção em que a perda aumenta.
- b) 40 ; cada atualização usa todos os 2.000 exemplos de uma vez.
- c) 20.000 ; uma atualização por exemplo, em cada época.
- d) 400 ; em cada uma, os pesos dão um passo na direção oposta ao gradiente, de tamanho definido pela taxa de aprendizado.

T08.

Relacione cada ano ao acontecimento:

(1) 1958; (2) 1969; (3) 1986; (4) 2012.

- I. Uma rede convolucional vence a competição ImageNet.
 - II. A retropropagação permite treinar redes com camadas ocultas.
 - III. O perceptron de Rosenblatt ajusta os próprios pesos a partir de exemplos.
 - IV. Minsky e Papert mostram que um neurônio só não resolve o XOR.
- a) 1-III; 2-IV; 3-II; 4-I
 - b) 1-IV; 2-III; 3-II; 4-I
 - c) 1-III; 2-II; 3-IV; 4-I
 - d) 1-II; 2-IV; 3-III; 4-I

Médias

T09.

Uma rede foi treinada por 50 épocas. A tabela mostra a perda em algumas delas:

Época	Perda no treino	Perda na validação
5	0,60	0,62
10	0,42	0,48
15	0,33	0,44
20	0,25	0,47
30	0,15	0,58
50	0,05	0,80

O que está acontecendo, e o que fazer?

- a) Alto viés: a perda de validação sobe porque a rede é pequena demais; acrescentar camadas e neurônios.
- b) A rede ainda está aprendendo, porque a perda de treino continua caindo; treinar por 100 épocas.
- c) Nada preocupante: ficar com os pesos da época 50, que têm a menor perda no treino.
- d) Sobreajuste a partir da época 15: ficar com os pesos da época de menor perda de validação (parada antecipada) e considerar rede menor, mais dados ou regularização.

T10.

Um grupo quer prever, **no momento da chamada ao 190**, se a ocorrência vai precisar de uma segunda viatura. A base tem as colunas: hora da chamada, bairro, tipo de ocorrência informado pelo solicitante e número de policiais que registraram presença no local. A acurácia de validação foi de 98%. O que o grupo deve fazer?

- a) Desconfiar do resultado e retirar a coluna “número de policiais no local”: ela só é registrada depois do atendimento e, quando há duas viaturas, ela já mostra isso.
- b) Retirar a coluna “hora da chamada”, porque a hora pode mudar entre o treino e o uso.
- c) Nada: 98% na validação, com dados separados do treino, mostra que a rede generaliza.
- d) Aplicar regularização, porque um acerto tão alto indica sobreajuste.

T11.

Uma ferramenta vai estimar o risco de reincidência de pessoas **sem registro anterior na base**. A base tem 10 mil registros de 3 mil pessoas: a mesma pessoa aparece em vários registros. Sorteando os **registros** entre treino e validação, a acurácia de validação foi de 88%. Sorteando as **pessoas** (todos os registros de uma pessoa ficam no mesmo conjunto), foi de 71%. Qual leitura é a correta?

- a) O sorteio por registros é melhor, porque usa os dados de forma mais equilibrada; o grupo deve relatar 88%.
- b) A diferença entre 88% e 71% é variação do sorteio; basta repetir a divisão algumas vezes e relatar a média.
- c) Sortear por registros põe a mesma pessoa no treino e na validação, o que é vazamento; o número que se parece com o uso é o do sorteio por pessoas.
- d) A queda indica sobreajuste; com regularização, o sorteio por pessoas chegaria aos 88%.

T12.

Para prever o número de roubos do mês seguinte em cada delegacia (série mensal do ISP-RJ, de 2014 a 2024), um grupo sortearou 20% dos meses para a validação. O erro de validação ficou muito baixo. Qual a crítica e a correção?

- a) Nenhuma: o sorteio garante que treino e validação se pareçam, e é isso que se espera de uma boa divisão.
- b) A validação deve ser posterior ao treino (por exemplo, treino até 2022, validação em 2023 e teste em 2024): no uso, a rede prevê o futuro a partir do passado, e no sorteio ela é avaliada em meses cercados por meses do treino.
- c) A validação está pequena; basta sortear 50% dos meses para que o erro fique confiável.
- d) Erro de validação muito baixo indica sobreajuste; aplicar regularização e manter o sorteio.

T13.

Um grupo testou o kNN com três valores de k . Resultados:

k	Acerto no treino	Acerto na validação
1	100%	68%
15	82%	79%
200	66%	65%

Qual leitura é a correta?

- a) $k = 1$ tem alta variância e $k = 200$, alto viés; escolher $k = 15$ pela validação e medir o desempenho final no teste.
- b) Escolher $k = 1$, que acertou 100% no treino.
- c) Escolher $k = 200$: como treino e validação estão quase iguais, não há sobreajuste, e esse é o melhor modelo.
- d) Os três têm o mesmo viés, porque são todos kNN; a diferença está só no ruído de cada amostra.

T14.

O erro em dados novos tem três fontes: ruído, viés e variância. Indique qual fonte cada ação ataca:

- (1) Dois atendentes dão naturezas diferentes à mesma chamada, e o grupo cria um manual com um critério de rotulagem mais claro.
 - (2) Uma rede pequena acerta pouco tanto no treino quanto na validação, e o grupo aumenta o número de neurônios.
 - (3) Uma rede acerta muito mais no treino que na validação, e o grupo junta mais dados de treino.
- a) (1) variância; (2) viés; (3) ruído
 - b) (1) viés; (2) ruído; (3) variância
 - c) (1) ruído; (2) variância; (3) viés
 - d) (1) ruído; (2) viés; (3) variância

T15.

Uma rede identifica, pelo texto do relato, ocorrências de violência doméstica. Nos dados de treino, quase todos os relatos dessa classe vieram de uma delegacia especializada, cujo sistema insere o nome da unidade no rodapé de cada relato. Numa validação sorteada da mesma base, o acerto foi de 96%. Como verificar se a rede aprendeu a tarefa ou um atalho?

- a) Sortear outra validação da mesma base e conferir se os 96% se repetem.
- b) Avaliar em relatos de violência doméstica registrados em outras delegacias e comparar relatos equivalentes com e sem o rodapé; se o acerto cai, a rede usava o rodapé.
- c) Comparar o acerto no treino e na validação: se forem próximos, a rede não está usando atalho.
- d) Aumentar a rede: uma rede maior aprende o padrão verdadeiro e deixa de lado o rodapé.

T16.

Um colega afirma: “Pelo teorema da aproximação universal, uma rede com uma camada oculta e neurônios suficientes acerta quase 100% em qualquer tarefa. Se a nossa não chegou lá, faltaram neurônios.” Qual é a correção?

- a) Nenhuma: se a rede não chegou perto de 100%, faltaram neurônios.
- b) O teorema só vale para redes sem função de ativação, então não se aplica a redes com ReLU.
- c) O teorema diz que existe uma rede que chega perto da função; não diz quantos neurônios são necessários, nem que o treino encontra os pesos, nem que a rede acerta casos novos. E o ruído dos dados nenhum modelo remove.
- d) O teorema exige muitas camadas ocultas; com uma camada só, a rede não aproxima curvas.

T17.

Pense nas três escolhas de todo modelo: classe de modelos, função de perda e otimização. Ao trocar uma regressão logística (do scikit-learn) por uma rede neural com camadas ocultas para uma classificação binária, o que muda?

- a) Mudam a classe de modelos (de função afim seguida da sigmoide para camadas de neurônios) e a otimização (do L-BFGS para a descida do gradiente, como o Adam); a perda, a entropia cruzada, é a mesma.
- b) Muda só a perda: a rede passa a usar o erro quadrático.
- c) Mudam as três: a regressão logística usa erro quadrático, e a rede, entropia cruzada.
- d) Nada muda: a rede é apenas uma regressão logística com mais pesos.

T18.

Num conjunto de dados, os pontos da classe 1 ficam dentro de um círculo, e os da classe 0, num anel em volta dele. Um modelo de um neurônio só, com sigmoide e sem camada oculta, foi treinado até a perda parar de cair, e ficou perto de 50% de acerto no treino e na validação. O que explica o resultado, e o que muda?

- a) Faltou treino; treinar por muito mais épocas resolve.
- b) O modelo é uma regressão logística, e sua fronteira de decisão é uma reta, que não separa um círculo de um anel; acrescentar uma camada oculta com alguns neurônios e ReLU, que permite fronteiras curvas.
- c) A perda está errada; trocar a entropia cruzada pelo erro quadrático resolve.
- d) A sigmoide limita a saída a $(0, 1)$; trocar a ativação da saída por ReLU resolve.