

Aula 3: Questões de treino

Deep Learning (DEPAI) · IASEG/PMERJ · Aula 3 (07/10)

Fáceis

T01.

Uma rede classifica a natureza da ocorrência entre furto, roubo e outro, com última camada `Dense(3, activation="softmax")`. Para um relato, ela deu 0,60 para furto, 0,30 para roubo e 0,10 para outro. Depois de mais treino, só a pontuação de roubo (o valor que entra na softmax) aumentou; as pontuações de furto e de outro não mudaram. O que acontece com as probabilidades desse relato?

- a) A de roubo sobe, e as de furto e de outro continuam 0,60 e 0,10, porque as pontuações delas não mudaram.
- b) As três sobem juntas, porque a softmax deixa todos os valores positivos.
- c) Nada muda, porque a softmax só olha a maior pontuação, que continua sendo a de furto.
- d) A de roubo sobe, e as de furto e de outro caem, mesmo sem mudar de pontuação: as três continuam somando 1.

T02.

Um grupo argumenta: “No fim, o que nos interessa é a acurácia. Então vamos treinar a rede usando a acurácia como perda, em vez da entropia cruzada.” Qual é o problema?

- a) Nenhum: a perda pode ser qualquer número que interesse ao grupo; trocar a perda só muda a velocidade do treino.
- b) A acurácia muda aos saltos: um pequeno ajuste num peso quase nunca muda um acerto, então a descida do gradiente não tem inclinação para seguir; e ela não distingue um acerto com 51% de certeza de um com 99%.
- c) A acurácia só pode ser calculada no conjunto de teste, nunca no treino.
- d) A acurácia é uma medida de regressão; em classificação, a única medida possível é a entropia cruzada.

T03.

Uma rede foi compilada com `optimizer=keras.optimizers.Adam(learning_rate=0.5)`. A saída do `fit` mostrou a perda de treino:

```
Epoch 1/50 - loss: 0.69  
Epoch 2/50 - loss: 2.85  
Epoch 3/50 - loss: 17.4  
Epoch 4/50 - loss: 312.6  
Epoch 5/50 - loss: nan
```

Qual é a causa mais provável, e o que fazer?

- a) Sobreajuste; usar `EarlyStopping` olhando a validação.
- b) A taxa de aprendizado está grande demais: cada passo passa do mínimo e cai cada vez mais longe; reduzir a taxa, por exemplo de volta ao padrão, 0,001.
- c) A rede é pequena demais para o problema; acrescentar camadas e neurônios.
- d) O lote é pequeno demais; aumentar o `batch_size` resolve sozinho.

T04.

Uma rede é treinada com:

```
parar = keras.callbacks.EarlyStopping(monitor="val_loss", patience=5,
                                     restore_best_weights=True)
modelo.fit(X_train, y_train, epochs=200, validation_split=0.2,
          callbacks=[parar])
```

A menor perda de validação aparece na época 23, e depois dela a perda de validação nunca mais melhora. Em que época o treino para, e com os pesos de qual época o modelo fica?

- a) Para na época 200; fica com os pesos da época 200.
- b) Para na época 23; fica com os pesos da época 23.
- c) Para na época 28; fica com os pesos da época 23.
- d) Para na época 28; fica com os pesos da época 28.

Médias**T05.**

Uma rede tem 1 entrada (a hora do dia, h , de 0 a 24), uma camada oculta com 2 neurônios ReLU e uma saída sem ativação. Depois do treino, ela calcula:

$$y = 2 \cdot \text{ReLU}(h - 6) - 3 \cdot \text{ReLU}(h - 14)$$

Quanto vale y às 4h, às 10h e às 18h, e que forma tem a curva?

- a) 0, 8 e 12; plana até as 6h, sobe até as 14h e depois desce: duas dobras, em pontos escolhidos pelo bias de cada neurônio.
- b) 26, 20 e 12; uma reta que desce o dia todo, porque a saída não tem ativação.
- c) 0, 8 e 36; plana até as 6h e depois sobe cada vez mais rápido.
- d) 0, 8 e 12; uma curva suave em forma de S, como a da sigmoide.

T06.

Dois modelos estimam o tempo de chegada de uma ambulância. Os erros, em minutos, em quatro ocorrências:

	Ocorrência 1	Ocorrência 2	Ocorrência 3	Ocorrência 4
Modelo A	4	4	4	4
Modelo B	0	0	0	12

Qual modelo cada perda prefere, e qual perda reflete melhor a ideia de que um atraso grande é muito mais grave que vários atrasos pequenos?

- a) O MAE prefere B (3 contra 4) e o MSE prefere A (16 contra 36); escolher o MSE, que pune mais o erro grande.
- b) As duas preferem B, que acerta em cheio três das quatro ocorrências; tanto faz a perda.
- c) O MAE prefere A e o MSE prefere B; escolher o MAE, por estar em minutos.
- d) O MAE prefere B (3 contra 4) e o MSE prefere A (16 contra 36); escolher o MAE, por ser a média dos erros “de verdade”.

T07.

Considere o treino:

```
modelo.fit(X_train, y_train, batch_size=64, epochs=30,
           validation_split=0.25)
```

`X_train` tem 12.000 linhas. Que número aparece no contador de lotes de cada época (o “N/N” da saída do `fit`), e quantas vezes os pesos são atualizados no treino todo?

- a) 188/188; 5.640 atualizações.
- b) 141/141; 4.230 atualizações.
- c) 140/140; 4.200 atualizações.
- d) 9000/9000; 270.000 atualizações.

T08.

Dois redes indicam se uma chamada é trote. Na validação, as duas acertam 90% das chamadas e, nos acertos, as duas dão cerca de 0,9 à resposta certa. A diferença está nos erros: quando erra, a rede A dá cerca de 0,4 à resposta certa; a rede B, cerca de 0,01. A perda de validação (entropia cruzada) é 0,19 para A e 0,56 para B. Qual leitura é a correta?

- a) A entropia cruzada pune muito mais o erro cometido com certeza: dar 0,01 à resposta certa custa cerca de 4,6, contra cerca de 0,9 ao dar 0,4. B erra “convicta”, o que é perigoso se as probabilidades forem usadas para priorizar chamadas.
- b) Deve haver um erro no Keras: com a mesma acurácia, as perdas teriam que ser iguais.
- c) B é a melhor rede: uma perda maior indica que ela aprendeu mais com os exemplos.
- d) B erra mais chamadas que A; a acurácia é arredondada e esconde essa diferença.

Difíceis**T09.**

Uma rede tem um peso só, e a perda é $\text{perda} = \text{peso}^2$. A inclinação é $2 \times \text{peso}$, e cada passo faz $\text{novo peso} = \text{peso} - \text{taxa} \times \text{inclinação}$. O peso começa em 2. Para que valor vai o peso depois de um passo com taxa 0,25, com taxa 1,0 e com taxa 1,5, e o que acontece se os passos se repetirem?

- a) 1, -2 e -4 . Com 0,25, o peso cai à metade a cada passo e chega ao mínimo; com 1,0, fica pulando entre 2 e -2 , sem sair do lugar; com 1,5, cada passo cai mais longe, e a perda cresce até virar **nan**.
- b) 1, -2 e -4 . Quanto maior a taxa, maior o passo e mais rápido o peso chega ao mínimo: a taxa 1,5 é a melhor.
- c) 1,5, 0 e -1 . Com taxa 1,0, o peso chega ao mínimo em um único passo.
- d) 3, 6 e 8. As três taxas fazem a perda subir, porque a inclinação é positiva.

T10.

Para separar os pontos do centro dos pontos do anel (Exercício 3 da Aula 2), um grupo usou `Dense(4, activation="relu")` na camada oculta e `Dense(1, activation="sigmoid")` na saída, com `Adam(learning_rate=0.5)`. A acurácia de treino travou perto de 67%, e a fronteira saiu quase reta. Inspeccionando a rede, o grupo viu que 3 dos 4 neurônios ocultos devolvem 0 para **todos** os pontos do treino. O que explica o resultado, e o que tentar?

- a) Sobreajuste: os neurônios zerados decoraram os pontos de treino; usar **EarlyStopping**.
- b) Neurônios mortos: a soma ponderada desses neurônios ficou negativa para todos os pontos, a ReLU devolve sempre 0 e a inclinação é 0, então o treino não os mexe mais. Tentar uma taxa menor, mais neurônios, outra semente ou Leaky ReLU.
- c) Faltaram épocas: com mais tempo de treino, os neurônios zerados voltam a responder sozinhos.
- d) A sigmoide da saída é que zera os neurônios ocultos; trocar a ativação da saída por ReLU.

T11.

Um modelo de triagem indica se uma chamada ao 190 é de violência doméstica. Na base de validação, 3% das chamadas são desse tipo. O modelo chegou a 97% de acurácia na validação, e a equipe quer colocá-lo em uso. O que precisa ser conferido antes?

- a) Nada: 97% está muito acima dos 50% de quem chuta ao acaso entre duas classes.
- b) Se o modelo encontra os casos reais: um modelo que responde “não” para todas as chamadas também tem 97% de acurácia. Olhar o recall da classe rara (de todos os casos reais, quantos ele encontrou).
- c) Se a perda usada foi o MSE, que é a perda adequada quando a resposta é uma porcentagem.
- d) Se a rede tem camadas suficientes, porque acurácia alta com classes desbalanceadas indica viés alto.

T12.

Uma rede que estima o tempo de chegada da viatura foi compilada com `loss="mse"` e `metrics=["mae"]`. Na última época, a saída do `fit` mostrou `val_loss: 25.0` - `val_mae: 3.0`, com os tempos em minutos. O comandante pergunta: “Em média, o modelo erra por quanto?” Qual é a resposta, e o que a comparação entre os dois números sugere?

- a) 25 minutos: a perda é o erro médio do modelo.
- b) 5 minutos, a raiz de 25: a raiz do MSE é o erro médio em minutos.
- c) 3 minutos, o MAE. O MSE está em minutos ao quadrado; como a raiz de 25 (5) é maior que 3, os erros não são todos parecidos: alguns erros grandes pesam muito no MSE.
- d) 3 minutos. A diferença entre 25 e 3 mostra que a rede está sobreajustada.