Reconhecimento de caracteres alfanuméricos

Uma imagem de 20 × 16 pixels. Uma classe entre 0-9 e A-Z.

Bruno Groppo · Bruno Pimentel · Reynato Junior
Wallace Jardim · Daniel Gil

Problema e referência de comparação

Entrada

Um caractere isolado, binário,
com orientação já definida.

Saída

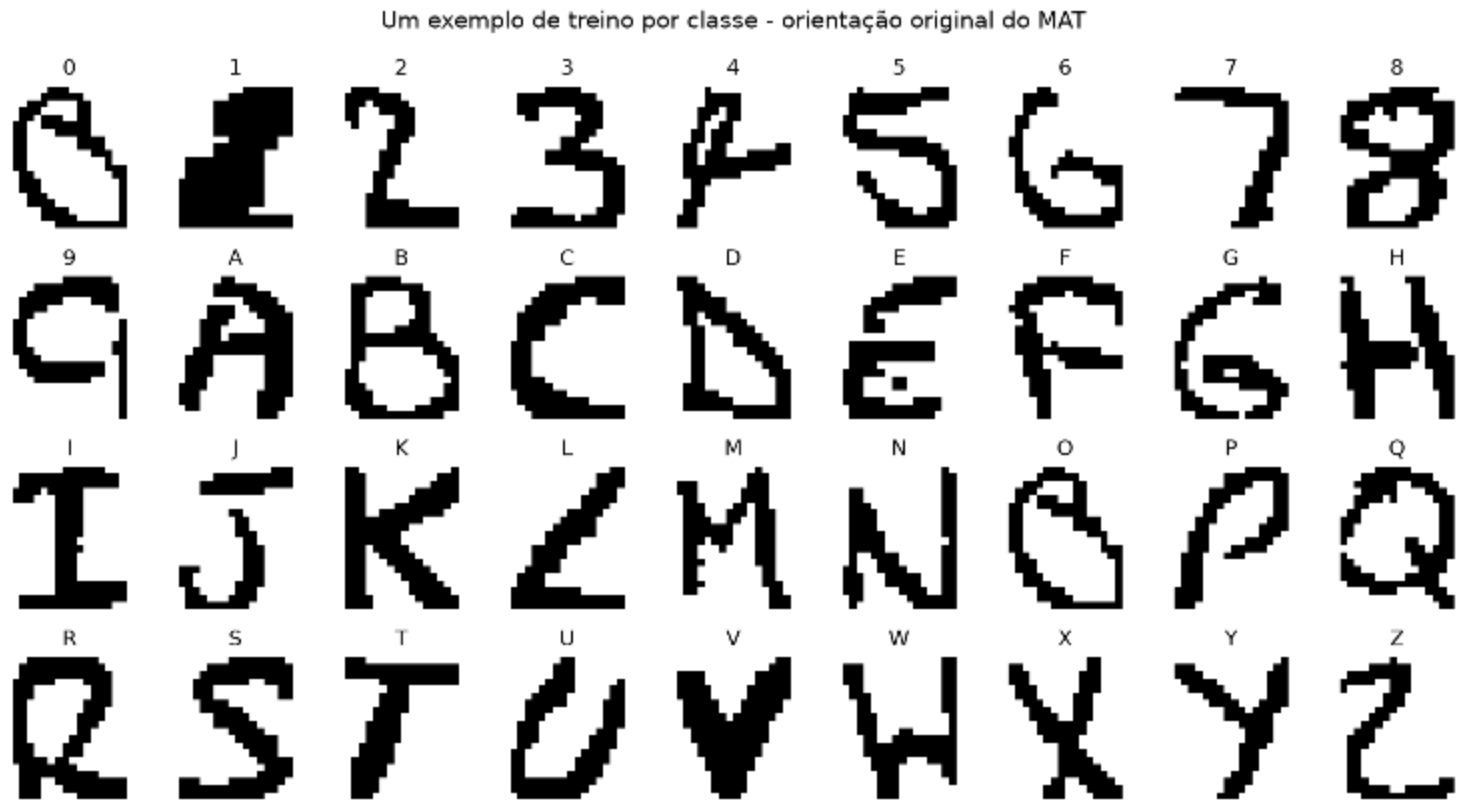
36 pontuações softmax.
Escolhemos a maior.

Baseline: sempre prever 0

6 acertos em 217 imagens de validação: 2,76%.
Uma MLP adicional compara a CNN com uma rede densa.

Binary Alpha Digits

1.404 imagens · 36 classes · 39 exemplos por classe



Cópias idênticas ficam no mesmo conjunto

As imagens de 0 e O são iguais, com rótulos diferentes.
O hash dos pixels define os grupos da divisão.

Conjunto	Imagens	Padrões únicos
Treino	971	943
Validação	217	210
Teste	216	210

Seed 42 · Nenhuma cópia exata atravessa os conjuntos

Arquitetura da CNN

Etapa	Saída por imagem
Entrada binária	20 × 16 × 1
Conv2D(16, 3, same, ReLU) + MaxPool	10 × 8 × 16
Conv2D(32, 3, same, ReLU) + MaxPool	5 × 4 × 32
Flatten + Dense(64, ReLU)	64
Dropout(0,3), só na melhoria	64
Dense(36, softmax)	36

48.164 parâmetros nas duas CNNs; Dropout não adiciona pesos.

Treinamento e seleção

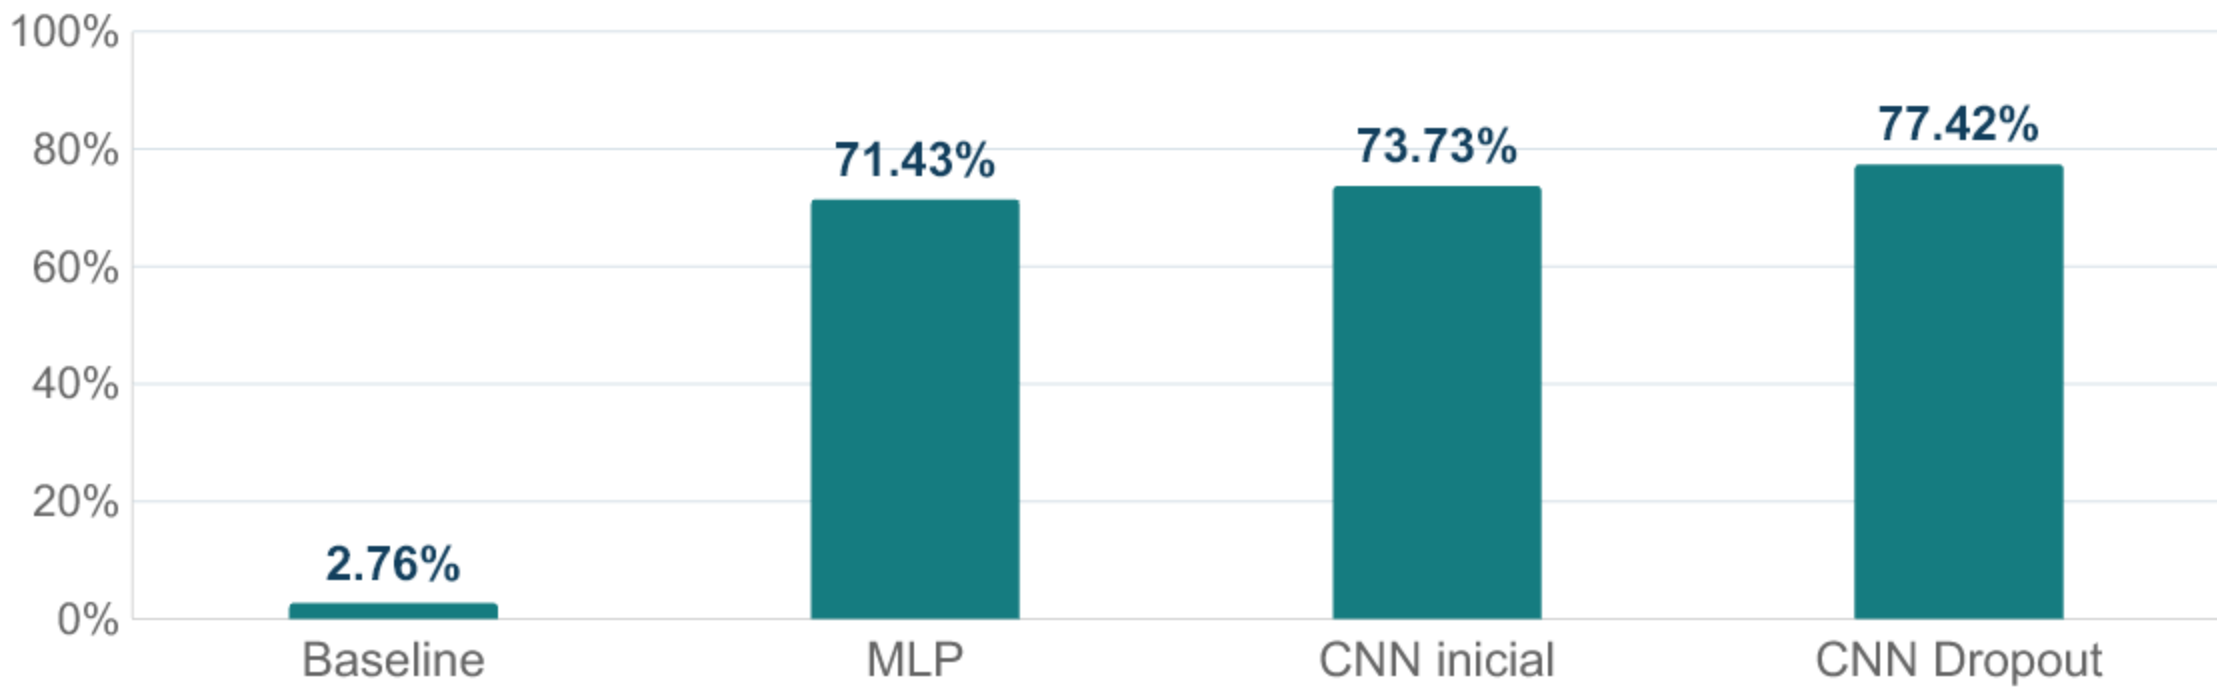
Adam: taxa 0,001
Batch: 32 imagens
Limite: 80 épocas

Perda: entropia cruzada
Rótulos inteiros (sparse)
Métrica principal: acurácia

EarlyStopping: dez épocas sem reduzir val_loss.
Restaurar os pesos da melhor época.

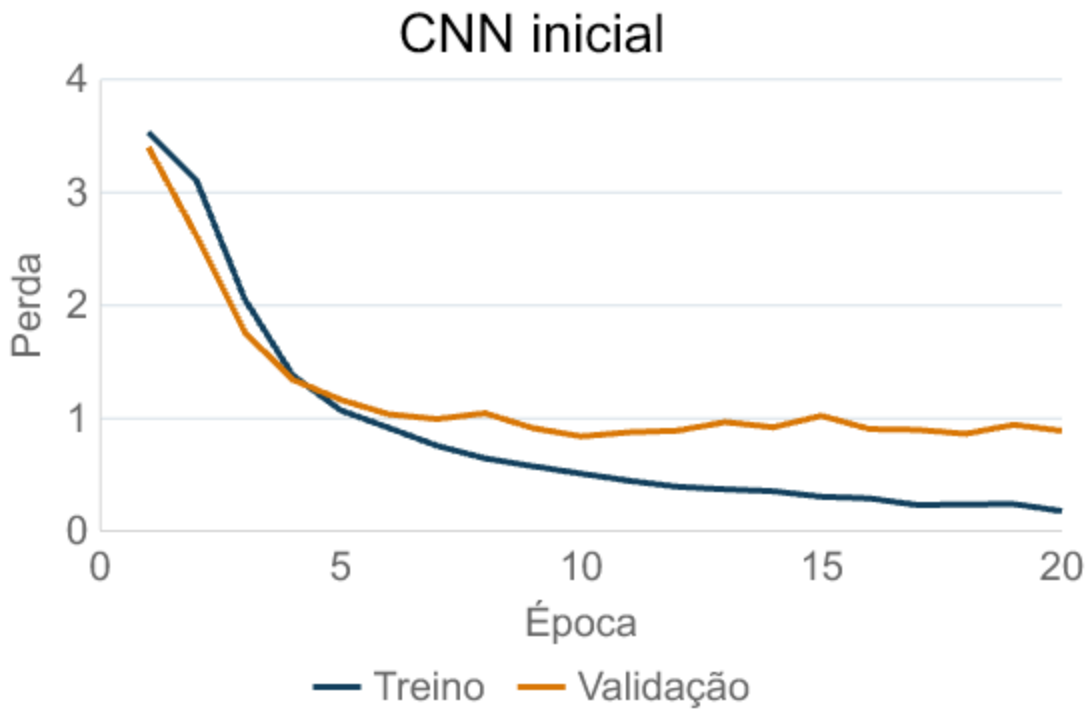
Selecionar pela validação. Avaliar no teste somente ao final.

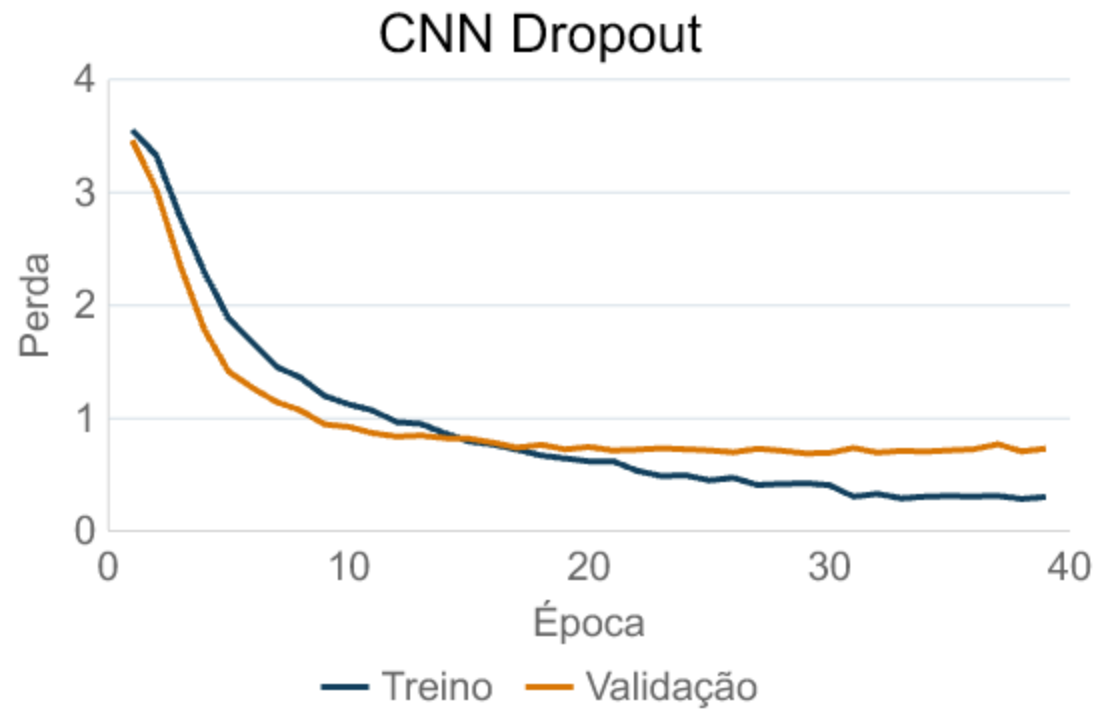
Dropout melhorou a validação nesta execução



CNN inicial: 73,73% → CNN Dropout: 77,42%
A melhoria foi acrescentar Dropout(0,3); o restante foi mantido.

Perda de treino e validação

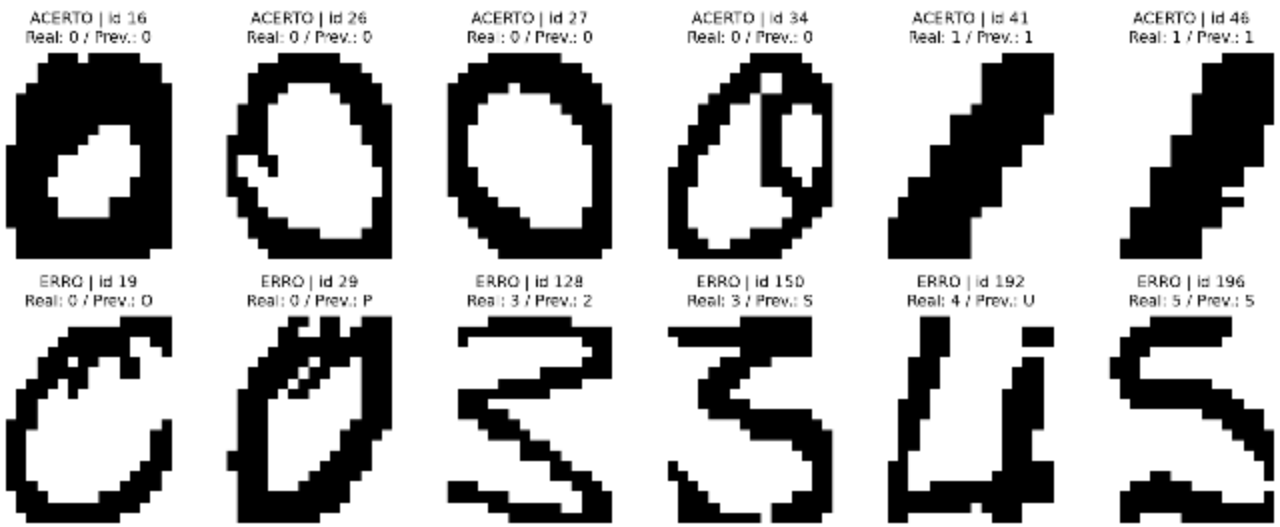




Pesos restaurados: época 10 na CNN inicial; época 29 com Dropout.
A validação estabiliza enquanto a perda de treino continua caindo.

Teste final: 178 acertos em 216 imagens

Modelo	Acurácia	Macro-F1
Baseline	2,78%	0,002
CNN Dropout	82,41%	0,817



38 erros

O → 0: 4 casos
S → 5: 2 casos

Uso pretendido e limitações

Demonstração de caracteres isolados, com revisão humana.

0/O: pixels idênticos, rótulos conflitantes.
Poucos exemplos por classe e uma única divisão.
Sem avaliação em fotografias, placas ou documentos reais.

Próximo passo: validar em dados externos e medir quando o modelo deve se abster, antes de propor qualquer aplicação operacional.