

Projeto da Disciplina 3 – Deep Learning

Prof. Rafael Stutz

O que vocês vão fazer

Em grupos de 4, vocês vão desenvolver uma solução de Deep Learning utilizando Keras, sobre um conjunto de dados escolhido pelo grupo. O objetivo é construir uma rede neural, treiná-la, avaliar seu desempenho e documentar tanto o processo quanto os resultados.

O modelo deve responder a uma pergunta bem definida. Ele pode realizar uma classificação ou uma regressão, desde que exista uma relação clara entre o problema, os dados disponíveis e a saída produzida.

O objetivo não é construir a rede mais complexa ou alcançar a maior acurácia. O importante é demonstrar que vocês compreendem as escolhas feitas, sabem avaliar o treinamento e conseguem reconhecer as limitações do modelo.

Prazos

Quando	O quê
Até a Aula 4	Aprovação definitiva do conjunto de dados e definição da tarefa. Distribuição das responsabilidades entre os integrantes.
21/10 às 23h59	Entrega do notebook e do relatório.
22/10	Apresentação e perguntas.

As datas definitivas serão informadas pelo professor. Conjuntos de dados fora da lista sugerida precisam ser aprovados antes do início dos experimentos.

O que vocês entregam

1. Um notebook no Google Colab, contendo todo o código necessário para carregar e preparar os dados, construir a rede neural, realizar o treinamento, avaliar os resultados e gerar previsões.

O notebook deve apresentar a sequência completa do trabalho e permitir sua reprodução, sem depender de arquivos privados ou caminhos locais dos integrantes.

2. Um relatório de no máximo 10 páginas, com seis seções obrigatórias, descritas a seguir.

3. Uma apresentação de até 15 minutos, com participação de todos os integrantes. As perguntas do professor serão feitas após a apresentação, em um período adicional.

As seis seções do relatório

N.	Seção	Responde a
1	Objetivo da modelagem	Qual problema vocês querem resolver? O que entra na rede e o que ela devolve? Por que utilizar Deep Learning?
2	Dados utilizados	De onde vieram os dados? Como foram explorados e preparados? Como foram divididos em treino, validação e teste?
3	Arquitetura e desempenho	Como a rede foi construída? Quais configurações foram utilizadas? Qual métrica foi escolhida? Como o resultado se compara ao baseline?
4	Análise do treinamento	O que aconteceu durante o treinamento? As curvas indicam aprendizado adequado, overfitting ou underfitting? O que vocês tentaram melhorar?
5	Limitações	Em quais situações o modelo erra? Quais tipos de exemplos apresentam maior dificuldade?
6	Uso pretendido e restrições	Para que o modelo poderia ser utilizado? Que decisões ele poderia apoiar? Em quais situações não deveria ser usado?

Cada seção terá um ou mais responsáveis definidos pelo grupo. Como são seis seções para quatro pessoas, a divisão não precisa ser igual.

Todos os integrantes devem compreender o funcionamento geral do projeto, inclusive as partes pelas quais não ficaram diretamente responsáveis.

Como escolher o conjunto de dados

Nesta disciplina, daremos preferência a projetos de **classificação de imagens e áudio**, que permitem explorar diferentes arquiteturas de redes neurais e técnicas de treinamento.

Também serão aceitos projetos com **dados tabulares, desde que relacionados à segurança pública**. Nesses casos, os grupos deverão considerar que Deep Learning nem sempre é a melhor abordagem para esse tipo de dado.

Não será permitido reutilizar conjuntos de dados trabalhados nas aulas, como o MNIST. O objetivo é aplicar os conhecimentos adquiridos a um problema diferente dos exemplos apresentados.

O conjunto de dados deve:

- Ser público e estar disponível para download;
- Ter entradas e saídas claramente definidas;
- Permitir formular um problema de classificação ou regressão;
- Permitir separar dados de treino, validação e teste de maneira adequada;
- Ter tamanho compatível com os recursos disponíveis no Google Colab;
- Permitir realizar e comparar experimentos durante o período da disciplina.

Conjuntos de imagens

Conjunto	Tarefa	Observação
CIFAR-10	Classificação de imagens	60 mil imagens coloridas de 10 categorias. Permite treinar CNNs e comparar arquiteturas.
Cats vs. Dogs	Classificação de imagens	Aproximadamente 23 mil imagens válidas. Classificação binária, adequada para CNNs e transfer learning.
Flowers	Classificação de imagens	3.670 imagens de flores de 5 categorias. Permite experimentar CNNs e transfer learning.
Beans	Classificação de imagens	1.295 imagens de folhas de feijão em 3 classes. Permite estudar classificação de doenças em plantas e generalização.
TrashNet	Classificação de imagens	2.527 imagens de resíduos de 6 categorias. Permite classificar materiais como plástico, papel e vidro.

Conjunto de áudio

Conjunto	Tarefa	Observação
UrbanSound8K	Classificação de áudio	8.732 gravações de 10 classes de sons urbanos, incluindo sirenes e disparos. Permite trabalhar com espectrogramas e CNNs.

Conjuntos tabulares de segurança pública

Conjunto	Tarefa possível	Observação
ISP-RJ	Regressão / séries temporais	Estatísticas de criminalidade do Rio de Janeiro. Permite prever quantidades futuras de ocorrências por período ou região.
Chicago Crimes	Classificação / regressão	Milhões de registros de crimes em Chicago. Permite estudar padrões de ocorrências e prever contagens futuras.
NYPD Complaint Data	Classificação / regressão	Milhões de registros de ocorrências em Nova York. Permite estudar padrões temporais e espaciais de criminalidade.

Os conjuntos acima são sugestões. Outras bases poderão ser utilizadas mediante aprovação do professor. **Projetos com dados tabulares deverão obrigatoriamente estar relacionados à segurança pública.**

Uso de subconjuntos dos dados

Não é necessário utilizar o conjunto de dados inteiro. Em bases extensas, como Chicago Crimes e NYPD, os grupos poderão trabalhar com subconjuntos (*subsets*), selecionando períodos, regiões, categorias ou amostras dos registros disponíveis.

A seleção deverá ser justificada e documentada. O grupo deverá explicar como ela foi realizada e quais limitações pode introduzir.

A divisão entre treino, validação e teste deve evitar vazamento de dados. Em problemas de previsão temporal, deverá respeitar a ordem cronológica das observações.

Restrição adicional:

Não será permitido reutilizar conjuntos de dados trabalhados nas aulas, como o MNIST. O objetivo é aplicar os conhecimentos adquiridos a problemas diferentes dos exemplos apresentados.

Cuidados importantes

- A divisão entre treino, validação e teste deve evitar vazamento de dados;
- Em problemas de previsão temporal, a avaliação deverá respeitar a ordem cronológica dos dados;
- Não poderão ser utilizadas informações que revelem diretamente a resposta que o modelo deveria prever;
- Quando o dataset possuir divisões oficiais, como os folds do UrbanSound8K, elas deverão ser respeitadas.

Escolha da abordagem

Não será necessário utilizar CNNs, RNNs e Transformers no mesmo projeto. Cada grupo deverá escolher uma abordagem adequada ao problema proposto.

Para dados tabulares, recomenda-se comparar a rede neural com um modelo tradicional de Machine Learning. O fato de uma rede neural não superar um modelo mais simples não será considerado um problema, desde que o grupo consiga interpretar e justificar os resultados.

Os experimentos mínimos

O projeto deverá conter uma comparação entre soluções, e não apenas o treinamento de uma única rede.

Por exemplo, para projetos de classificação de imagens, o caminho recomendado é:

1. **Modelo de referência (baseline):** uma solução simples, como prever sempre a classe mais frequente.
2. **Primeira rede neural:** uma CNN pequena, construída e treinada pelo grupo utilizando Keras.
3. **Segundo experimento:** uma melhoria justificada como data augmentation, regularização, ajuste da arquitetura ou transfer learning, quando aplicável.

Para outras modalidades de dados, o grupo deverá propor experimentos equivalentes.

Não é necessário testar muitas arquiteturas. É preferível realizar poucos experimentos, mas compreender por que foram feitos e o que seus resultados mostram.

Como avaliar os modelos

Os dados deverão ser separados em três conjuntos:

- **Treino:** utilizado para ajustar os pesos da rede;
- **Validação:** utilizado para acompanhar o treinamento e escolher configurações;
- **Teste:** utilizado para avaliar o modelo escolhido ao final.

A seleção dos modelos não poderá ser feita com base no desempenho do conjunto de teste.

O grupo deverá apresentar:

- Uma métrica adequada à tarefa;
- Comparação com o baseline;
- Curvas de treinamento e validação;
- Análise de possíveis sinais de overfitting ou underfitting;
- Pelo menos uma tentativa de melhoria, acompanhada de sua justificativa;
- Exemplos de previsões corretas e incorretas, quando aplicável.

O que está sendo avaliado

Um modelo que não alcança um bom desempenho pode receber uma boa avaliação, desde que o grupo consiga explicar os resultados, identificar os problemas e justificar o que faria de maneira diferente.

A avaliação considerará:

- A coerência entre problema, dados e saída da rede;
- O uso correto dos recursos básicos do Keras;
- A justificativa das escolhas de arquitetura, função de perda e métricas;
- A comparação com uma referência;
- A capacidade de interpretar o treinamento;
- A identificação de erros, limitações e riscos do uso pretendido.

O que não está sendo avaliado: a obtenção da maior acurácia ou o uso da arquitetura mais sofisticada.

Distribuição da nota

Componente	Peso
Notebook e implementação	20%
Relatório e análise dos resultados	30%
Apresentação do projeto	40%
Respostas às perguntas	10%

A apresentação e as perguntas

Cada grupo terá **até 15 minutos para apresentar o projeto**. Após esse período, haverá uma rodada de perguntas do professor. **O tempo das perguntas não está incluído nos 15 minutos da apresentação.**

Todos os integrantes deverão participar da apresentação.

Distribuição sugerida:

Etapas	Tempo	Conteúdo
Problema e dados	3 min	Objetivo, dataset e preparação dos dados.
Construção da rede	4 min	Arquitetura, camadas, ativações, função de perda e treinamento.
Experimentos e resultados	4 min	Baseline, modelos testados, métricas e comparações.
Análise crítica	3 min	Curvas de aprendizado, erros, limitações e melhorias.
Conclusão	1 min	Principais resultados e aprendizados.

Após a apresentação, as perguntas serão feitas pelo professor a integrantes específicos. Elas poderão abordar qualquer etapa do projeto, e não apenas a parte apresentada por cada pessoa.

As questões estarão relacionadas ao trabalho realizado, como decisões de implementação, interpretação das curvas de treinamento, escolha das métricas e análise dos erros.

Um banco de perguntas orientadoras será disponibilizado previamente para ajudar na preparação.

Antes de entregar

Confiram se:

- O notebook executa no Google Colab;
- Os dados podem ser carregados sem depender de arquivos locais;
- O treinamento e a avaliação estão documentados;
- As comparações não usam o teste para escolher o modelo;
- O relatório contém as seis seções;
- Todos conseguem explicar o projeto;
- A apresentação respeita o limite de tempo.