PROJETO ACADÊMICO / GRUPO 4

RECONHECIMENTO DE CARACTERES ALFANUMÉRICOS



Deep Learning aplicado a imagens binárias

36 CLASSES • 1.404 IMAGENS • 20 × 16 PIXELS

Bruno Groppo • Bruno Pimentel • Reynato Junior • Wallace Jardim • Daniel Gil

O que queremos construir?

PROBLEMA

Identificar automaticamente um único caractere apresentado em uma imagem binária.

Sem palavras completas e sem várias letras na mesma imagem.

ENTRADA

Imagem de 1 caractere

SAÍDA

Classe prevista: A–Z ou 0–9

36

classes

26

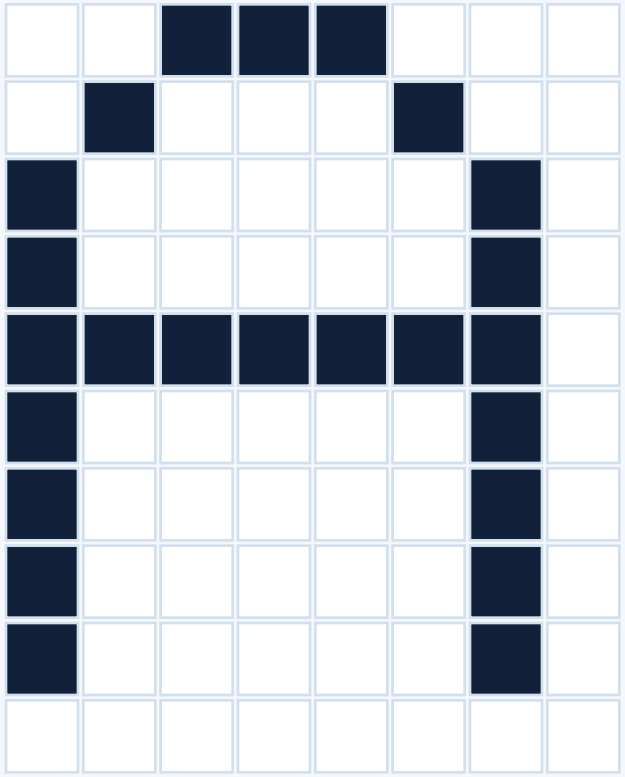
letras maiúsculas

10

algarismos

Como o computador vê um caractere?

Exemplo ilustrativo: uma letra A como grade de pixels



Cada quadradinho é um pixel. Em uma imagem binária, utilizamos apenas dois estados possíveis, como 0 e 1.

NOSSO DATASET

20 × 16 × 1 = 320 valores por imagem

Altura × largura × canais

O dataset: Binary Alpha Digits

1.404
imagens

39
exemplos por classe

36
classes

CONFIRMADO

Arquivo .rda aberto como DataFrame com 1.404 linhas e 320 colunas; valores encontrados: 0 e 1.

AINDA PRECISA SER VALIDADO

Correspondência entre cada imagem e seu rótulo; orientação correta dos pixels; integridade da conversão.

Fonte: tensorflow.org/datasets/catalog/binary_alpha_digits

Cópia alternativa de dados: pacote loon.data (R). Não treinar antes da validação.

Do dataset à previsão

01

Validar dados

Imagens + rótulos

02

Separar conjuntos

Treino / val. / teste

03

Treinar baseline

Rede simples (MLP)

04

Treinar CNN

Aprender padrões

05

Avaliar

Métricas + erros

Por que comparar MLP e CNN?

O baseline (MLP) serve de referência. A CNN será avaliada para verificar se aprender padrões espaciais melhora o reconhecimento.

Como dividiremos as 1.404 imagens?

Proposta: 27 para treino, 6 para validação e 6 para teste POR CLASSE.



TREINAMENTO

27 × 36 = 972

Aprender

VALIDAÇÃO

6 × 36 = 216

Ajustar decisões

TESTE

6 × 36 = 216

Prova final

Divisão estratificada: manter todas as 36 classes representadas em cada conjunto.

Recomendação: fixar seed e reservar teste até a avaliação final.

Entregas, riscos e próximos passos

ENTREGAS

- ✓ Dados auditados e documentados
- ✓ MLP de referência e CNN treinada
- ✓ Accuracy, F1, curvas e matriz de confusão
- ✓ Relatório + demonstração simples

RISCOS A CONTROLAR

- Poucos exemplos por classe (39)
- Rótulos / orientação ainda não validados
- Overfitting e avaliação instável
- Evitar prometer desempenho antes de medir

DECISÃO RECOMENDADA PARA O GRUPO

Validar imagens e rótulos primeiro. Depois dividir os dados, treinar baseline, comparar CNN e registrar resultados reais.